

1. α, β -Crown에서 제공하는 모델, configuration, verification setup

1) model

a,b-crown 디렉토리에서 complete_verifier/models를 따라가면 볼 수 있는데, MNIST, CIFAR-10/100 등 이미지 분류용 테스트용으로 만들어진 데이터셋에 대해 학습된 모델인 CNN/ ResNet 모델에 대해 제공을 하고, 그 외에도 ACASXu 벤치마크나 제어 관련 문제에 대한 모델까지 검증이 가능하도록 전학습된 모델을 제공한다.

2) configuration

중요한 검증 파라미터는 exp_configs 디렉토리의 YAML 파일을 통해 관리가 되는데, 이 설정 파일에는 모델 경로, 데이터셋 로더, 하드웨어 설정, 그리고 a-crown, b-crown의 BaB 파라미터가 정의되어있다. 그리고 적대적 강건성 입증을 위한 PGD 등의 적대적 공격 파라미터도 포함되어 있어, ASR 평가할 때와 유사하게 모델의 취약점을 탐색할 수 있다.

3) Verification setup

검증 설정을 하기 위해, 입력 섭동을 정의하고, 또 엡실론 범위를 위해 설정하는 L-p 놈, 등을 정의한다. 위 설정대로 결정을 한 후, 검증을 하면 검증 결과로는 verified, Falsified, Timeout이 있는데, 위 규칙대로 했을 때, 검증에 실패하면 반례를 찾았다는 뜻으로 Falsified가 발동되는 것이다.

2. α, β -Crown configuration

```
model:
  # "model" refers to model.py, "build_model" is the function name
  name: Customized("train", "build_model")
  path: ./mlp_mnist.pth
data:
  # Target dataset (automatically downloaded if not present)
  dataset: MNIST
  # Verification range (e.g., verify from the 0th to 9th test image)
  start: 0
  end: 10
specification:
  # Robustness radius (\epsilon) for L_inf norm
  epsilon: 0.05
solver:
  # Batch size for GPU processing (adjust based on your VRAM)
  batch_size: 256
bab:
  # Branch and Bound timeout in seconds per image
  timeout: 120
```

config 파일은 다음과 같이, 간단하게 작성해놨으며, 저번 marabou와 다르게 이번에는 MNIST 데이터셋에서 행했고, 데이터는 0번째에서 10번째만 실험을 수행하였다. 또한 config에서 epsilon을 0.05로 하여서 L 인피니티 놈에서 강건성을 증명하고자 하였다. 또한 엡실론 0.01에서도 실험을 진행하였고 결과는 뒤에 반영하겠다.

모델은 marabou와 비교하기 위해, marabou에서 사용한 신경망과 똑같이 가져왔는데, 이번 실험에서 진행한 모델은 다음과 같다.

```
class MLP(nn.Module):
    def __init__(self):
        super(MLP, self).__init__()
        # Flatten the input tensor (e.g., 28x28 image to 784 vector)
        self.flatten = nn.Flatten()
        self.fc1 = nn.Linear(784, 32)
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(32, 10)

    def forward(self, x):
        x = self.flatten(x)
        x = self.fc1(x)
        x = self.relu(x)
        x = self.fc2(x)
        return x
```

데이터셋을 저번 마라부 환경 때와 다르게, F-MNIST가 아닌 MNIST로 설정한 이유는 "Marabou와 alpha, beta-CROWN이라는 두 검증 도구 자체의 구조적 차이와 연산 효율성만을 순수하게 비교하기 위해, 데이터셋에서 발생할 수 있는 복잡도를 최소화하고자이다.

엡실론을 0.01과 0.05로 했을 때, 2개의 linear 층에 대한 검증 결과는 다음과 같다.

epsilon	테스트 데이터	검증 성공	방어 실패	시간 초과	검증 정확도	평균 검증 시간	최대 검증 시간
0.01	10	10	0	0	100.00%	0.563초	1.211초
0.05	10	0	10	0	0.00%	0.081초	0.597초

엡실론이 0.01일 때, 엡실론이 0.05일 때보다 강건성을 검증한 데이터가 더 많은 것을 볼 수 있다. 엡실론이 0.05일 경우, 데이터들이 모델의 클래스를 결정하는 바운더리를 전부 넘어가는 것을 볼 수 있다.

엡실론이 0.05일 때 검증시간이 더 짧은 이유는 검증이 시작되자마자 PGD 공격으로 인한 반례가 조기 발견되어서 금방 검증이 끝났기 때문에 검증 시간이 더 짧은 것이다.

또한 엡실론이 0.01일 때의 반례가 존재하는 지 더 찾아보기 위해, 데이터 검증할 때의 개수를 늘려보았다.

```
##### Summary #####
Final verified acc: 98.0% (total 50 examples)
Problem instances count: 50 , total verified (safe/unsat): 49 , total falsified (unsafe/sat): 1 , timeout: 0
mean time for ALL instances (total 50):0.49567246060366704, max time: 1.2338159084320068
```

50개까지 늘렸을 때, 다음과 같이 하나의 데이터 샘플에서만 반례를 찾을 수 있었다.